论文大纲：

写作定位

复现 + 诊断 + 改进的实证研究：先说明 Deep CORAL 在哪里失效、为什么失效，再说明哪种修补有效、哪种无效、原因是什么。重点在改进部分（第 5、6 节）。

数据与证据见仓库根目录的 report.md 和各阶段的 `results/` 目录。

摘要（骨架）

1. Deep CORAL 用协方差对齐做无监督域适应，但它的增益依赖几个没有被检验过的假设。
2. 按原作者发布的 Caffe 配置忠实复现，得到显著但只有原文一半的增益（+1.0 对 +2.0），并发现其 λ 选择规则不可靠、batch 内的对齐损失以估计噪声为主。
3. 在 CORAL 上加入目标域信息最大化，4 个任务平均提高 9.0 个点；增益几乎全部来自信息最大化，CORAL 的主要作用变成抑制过度自信。
4. 用伪标签补上类别信息的两种做法都无效；我们给出诊断：信息最大化之后，从模型自身得到的伪标签已带不来新信息。

1. 引言

- **动机**：Deep CORAL 简单、常被用作基线，但原文增益只有 +2.0，且没有检验它的前提。
- **研究问题**：
  - RQ1：能否忠实复现？差距来自哪里？
  - RQ2：它的隐含假设（A1–A4）是否成立？
  - RQ3：针对失效之处，哪种修补有效？
  - RQ4：修补无效时，原因是什么？
- **贡献**：
  - 一次对齐原作者配置的复现，加上差距归因；
  - 对四个隐含假设的定量检验；
  - 一个简单有效的组合（CORAL + IM），以及对其增益来源的拆解；
  - 一个有诊断的负结果：伪标签类条件对齐为什么无效。

2. 相关工作

- 基于统计量差异的域适应：CORAL、Deep CORAL、DDC、DAN（MMD）、Log-CORAL。
- 对抗式与条件对齐：DANN、CDAN。
- 熵最小化与信息最大化：熵正则、RIM、SHOT。
- 伪标签与类条件对齐：MSTN、CAN、SHOT 的聚类伪标签。

- 域适应中的模型选择与校准：SND、DEV、TransCal。
- 机器学习复现研究。

3. 复现（压缩到约 1 页，作为后文的基础）

- **3.1 设置**：Office-31，6 个任务；对齐原作者 Caffe 配置的对照表。
- **3.2 结果**：Table 1，加配对增益和 95% 置信区间。
- **3.3 差距归因**：torchvision 骨干占 −8.2，学习率调度占 −0.9；和原作者训练日志对比，差距从第 100 步就存在。
- **证据**：`stage1_reproduction/results/stage1_summary.md` 、 `figures/fig2_*.png` 、`official_reference.json` 。

4. 诊断：Deep CORAL 的隐含假设（引出改进的动机）

每一节写成“现象 → 结论 → 对改进的启示”：

节	假设	关键证据	对改进的启示
4.1	A4：λ 能无标签设定	规则 λ 的解不唯一，让 D→A −6.4；无标签指标都偏向直接优化它的选项	新方法的超参数要事先固定，并做敏感性分析
4.2	A3：batch 估计可靠	batch 损失是真实距离的 3–7 倍	二阶对齐在训练后期提供的有效信号很弱
4.3	“退化特征”之说	λ 增大时有效秩不降反升，预测反而更分散	CORAL 是在压低置信度，而不是压缩特征
4.4	A1、A2	原文完全不利用目标域自身的结构	补上目标域结构，即信息最大化

证据：`offline_analysis/results/offline_summary.md` 、 `offline_findings.md` 、 `figures/erank_ece.png` 。

5. 方法（主要部分之一）

- **5.1 CORAL + 信息最大化**
  - 公式：L = L_cls + λ·L_CORAL + β·(单样本熵 − 平均预测的熵)。
  - 设计说明：两项为什么都需要（只做熵最小化会塌缩）；β 事先固定为 0.3；λ 沿用原作者取值。
  - 和 RIM、SHOT 的关系，如实说明哪些是已有的做法。
- **5.2 类条件扩展**（针对 A2）
  - 按类对齐均值和协方差。
  - 样本太少的问题：每类每个域维护 32 个样本的特征队列，梯度只回传到当前 batch。
- **5.3 三种伪标签来源**
  - 置信度阈值；
  - 特征空间类中心；

- 类中心与预测一致的样本；
- 另加一个可选的自训练项。

代码：`coral/losses.py`、`coral/pseudo.py`、`train.py`。

6. 实验（主要部分之二）

- **6.1 评估协议**
  - 超参数事先固定；同种子配对，给出 95% 置信区间；
  - 只跑 4 个非饱和任务，说明 D↔W 为什么排除；
  - 指标：准确率、ECE、NLL。
- **6.2 主结果**：CORAL + IM 比 Deep CORAL 高 +9.0 [+6.4, +11.5]，4 个任务都显著（表 + 训练曲线）。
- **6.3 增益拆解**：只加 IM 就有 +9.1；IM 之上再加 CORAL 只多 +1.4，只有 D→A 显著。核心论点：瓶颈不在二阶对齐。
- **6.4 消融**
  - 去掉多样性项后塌缩到 2–17 个类，准确率降到 3.5–16.5%；
  - β 取 0.1–1 时结果都稳定高于 Deep CORAL。
- **6.5 校准：CORAL 的新角色**：IM 让 NLL 升到 8.1，加上 CORAL 后降到 4.2；CORAL 单独使用时也一贯降低 ECE。
- **6.6 类条件对齐（负结果）**：置信度伪标签 +0.2，类中心伪标签 ±0.0；只对齐均值、只对齐协方差、γ 敏感性也都没有稳定趋势。
- **6.7 为什么无效：自洽性上限**
  - 置信度 ≥ 0.9 的样本占 98.7%，但其中只有 76.4% 正确；
  - 类中心标签与预测 98% 一致；
  - 伪标签准确率没有下降，所以不是确认偏差；
  - 结论：伪标签受限于模型自身，需要模型之外的信息来源。
- **6.8 模型选择**：最后一轮接近最优；无标签指标不能用来比较方法（它们偏向直接优化自己的方法）。

证据：`stage2_improvement/results/`、`stage3_class_conditional/results/`、`stage4_pseudo_labels/results/`。

7. 讨论

- **Deep CORAL 什么时候有用**：源域大、λ 合适的任务（A→W、A→D）。
- **对实践的建议**
  - 把 CORAL 当作校准正则项，而不是主要的对齐手段；
  - 报告结果时给出配对置信区间，并说明超参数是怎么选的。
- **局限**
  - 只用了 AlexNet 级骨干；改进实验只有 3 个种子；

- 原作者的 λ 可能参考过目标结果；
- 没有和 DANN、CDAN 等方法在同一套设置下比较。

8. 结论

附录

- 实现细节：CaffeNet 权重转换、Caffe 风格的 SGD、预处理。
- 完整的每任务表格；和原作者日志的逐任务对比。
- 代码与复现命令（指向仓库 README）。

需要补的实验

实验	为什么需要	规模
同一设置下的对比方法：DANN、DAN（MMD），最好加 CDAN	不然无法说明 +9 处在什么水平；目前只和 Deep CORAL 比	约 24 次 + 新代码
自训练 3 个种子	它是 6.7 节“自洽性上限”论点唯一的反例，必须确认或排除	12 次
消融和敏感性补到 3 个种子	现在只有 1 个种子，论文里不够	约 24 次
D→W、W→D 也跑 CORAL + IM	证明没有在饱和任务上掉点	6 次