Deep CORAL 复现与改进报告

摘要

在 Office-31 上复现了 Deep CORAL（Sun & Saenko, 2016），并在复现的基础上检验了它的隐含假设、尝试了三个改进，共 239 次训练。

- **复现**：第一次用 torchvision AlexNet 复现时，无适应基线 6 个任务平均只有 63.5%，比论文低 6.6 个点。从原作者仓库拿到了 Caffe 配置和训练日志，逐项对齐后，基线达到 69.4%（论文 70.1%），Deep CORAL 达到 70.3%（论文 72.1%）。Deep CORAL 的配对增益为 +1.0 [+0.3, +1.6]，显著为正，但只有论文 +2.0 的一半。第一次的差距几乎全部来自预训练骨干（−8.2）。
- **诊断**：论文“训练结束时两项损失相等”的 λ 选择规则解不唯一，用它选出的 λ 会让 D→A 掉 6.4 个点；不用目标标签的指标也选不出合适的 λ。训练中的 batch CORAL 损失是真实域距离的 3–7 倍，后期主要在优化估计噪声。λ 过大时特征的有效秩不降反升，与论文“退化特征”的说法不符。
- **改进**：加入目标域信息最大化（IM）后，在 A→W、A→D、D→A、W→A 四个任务上平均比 Deep CORAL 高 9.0 个点 [+6.4, +11.5]，四个任务都显著。增益几乎都来自 IM 本身，CORAL 在其上只再贡献 +1.4。两种基于伪标签的类条件 CORAL 都没有额外提升；诊断表明 IM 之后，从模型自身得到的伪标签已带不来新信息。

1. 背景

Deep CORAL 在网络的最后一层（fc8，31 维 logits）上，让源域和目标域特征的协方差矩阵相互靠近：

$$\mathcal{L}_{\mathrm{CORAL}} = \frac{1}{4d^2}\,\|C_S - C_T\|_F^{\,2}, \qquad \mathcal{L} = \mathcal{L}_{\mathrm{cls}} + \lambda\cdot\mathcal{L}_{\mathrm{CORAL}}$$

其中协方差在每个 batch 内估计，λ 按“训练结束时分类损失与 CORAL 损失大致相等”来选。我们把方法的有效性拆成四个隐含假设，后文逐一检验：

编号	隐含假设	检验结果
A1	二阶统计量足以刻画域差异	部分不成立：只用 IM、不对齐任何统计量，就比 Deep CORAL 高 7.5 个点
A2	只对齐边缘分布即可，无需类别信息	无法用伪标签补上：伪标签来自模型自身，类条件对齐没有额外提升
A3	batch 内协方差能可靠估计总体协方差	不成立：batch 损失是真实距离的 3–7 倍
A4	λ 可以在没有目标标签时设定	不成立：规则选出的 λ 让 D→A −6.4，无标签指标都选不出合适的 λ

2. 实验设置

数据：Office-31 的 Amazon（2817 张）、DSLR（498 张）、Webcam（795 张）三个域，31 类，6 个迁移任务。按无监督域适应的标准协议，使用全部有标签源域和全部无标签目标域训练，在全部目标域图像上测试，报告第 2000 次迭代的准确率。

与原作者对齐的训练设置：

项目	原作者（Caffe）	第一次复现	最终复现
网络与权重	BVLC Reference CaffeNet	torchvision AlexNet	CaffeNet，由官方 caffemodel 转换
输入预处理	BGR 减均值，227 裁剪，OpenCV 缩放	RGB 归一化，224 裁剪，PIL 缩放	同原作者
学习率	10^{-3}，每 500 步 ×0.1	10^{-3} 固定	同原作者
SGD 动量	学习率乘进动量	PyTorch 写法	同原作者
epoch 末尾不满一个 batch	接到下一轮	丢弃	同原作者
测试	中心裁剪 + 随机翻转	中心裁剪	同原作者
λ	每任务单独设定（0.0001–0.8）	—	原作者 λ；另做无标签规则对照

其余设置与论文一致：fc8 为 31 维、N(0, 0.005) 初始化、学习率 ×10；偏置学习率 ×2、不做权重衰减；源域、目标域各 128 张；动量 0.9，权重衰减 5×10^{-4}，2000 次迭代。

统计：阶段一每个配置 5 个种子，改进实验 3 个种子。同一种子下各方法的 fc8 初始化、数据顺序、数据增强和 Dropout 掩码完全相同，所以增益都用同种子配对差值，给出 95% 置信区间（t 分布）；区间跨 0 视为不显著。改进实验的超参数全部事先固定，不用目标标签挑选。

3. 复现

3.1 第一次复现与差距排查

第一次复现使用 torchvision 的 ImageNet 预训练 AlexNet，无适应基线 6 个任务平均 63.5%，比论文低 6.6 个点。训练日志显示，目标域准确率在第 100 步就到了最终水平，之后基本不变，所以差距不在训练时长或调度，而在预训练网络和输入处理。

原作者在 VisionLearningGroup/CORAL 仓库公开了 D-CORAL_Office31：Caffe 网络定义、求解器配置，以及 6 个任务 × 5 次运行的训练日志。这些日志的最后一轮平均值与论文表 1 的 D-CORAL 一栏完全一致，说明论文报告的是最后一轮。原作者的 CORAL 损失层与我们的实现相同（无偏协方差、除以 $4d^2$），所以他们的 λ 可以直接使用。

3.2 Table 1

方法	A→D	A→W	D→A	D→W	W→A	W→D	平均
CNN（论文）	63.8	61.6	51.1	95.4	49.8	99.0	70.1
CNN（复现）	62.6 ± 0.2	60.2 ± 1.2	51.6 ± 0.9	94.8 ± 0.3	48.3 ± 0.7	98.7 ± 0.6	69.4
D-CORAL（论文）	66.8	66.4	52.8	95.7	51.5	99.2	72.1
D-CORAL（复现）	65.0 ± 1.5	63.7 ± 1.4	50.9 ± 0.8	94.7 ± 0.3	48.6 ± 0.8	99.0 ± 0.5	70.3
原作者 λ	0.05	0.8	0.001	0.0001	0.0007	0.0001	

复现为 5 个种子的均值 ± 标准差（%）。

配对增益（D-CORAL − CNN）：

	A→D	A→W	D→A	D→W	W→A	W→D	平均
论文	+3.0	+4.8	+1.7	+0.3	+1.7	+0.2	+2.0
复现	+2.4	+3.6	−0.7	−0.1	+0.3	+0.4	+1.0
95% CI	[+0.4, +4.4]	[+2.1, +5.0]	[−1.0, −0.3]	[−0.5, +0.3]	[−0.2, +0.7]	[+0.0, +0.7]	[+0.3, +1.6]

按方案的验收标准：基线与论文相差 −0.8，在 ±2 以内，通过；A→W、A→D 的增益为正，与论文方向一致；6 任务平均增益 +1.0，比论文 +2.0 低 1.0，刚好落在 ±1 的边界外。D→W 与 W→A 的增益不显著；D→A 显著为负，但原作者在该任务上的 λ 只有 0.001，CORAL 的作用本来就很小。

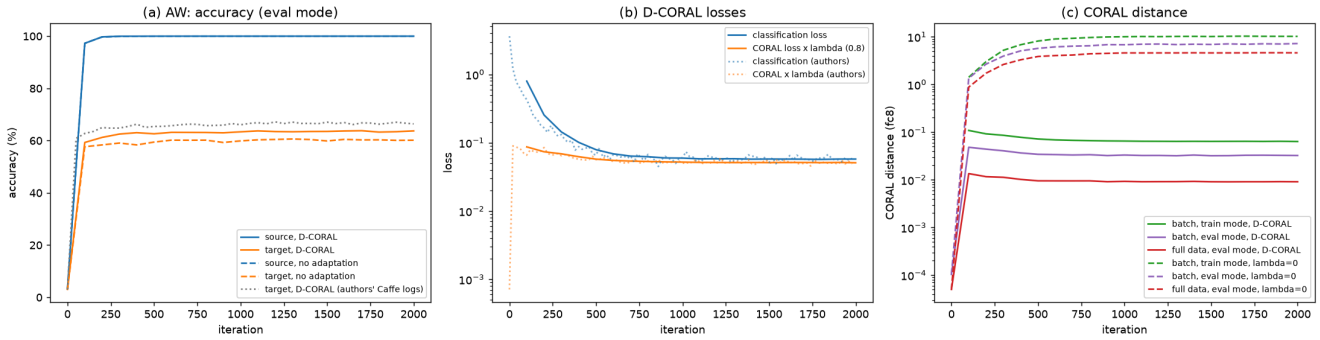
3.3 差距归因

在最终配置上，每次只把一项换回第一次复现的做法，跑无适应基线（A→W、A→D、D→A、W→A 四任务平均，%）：

设置	A→D	A→W	D→A	W→A	平均	与最终配置的差
最终配置	62.6	60.2	51.6	48.3	55.7	—
只换固定学习率	61.6	58.0	51.3	48.4	54.8	−0.9
只换 torchvision 骨干	55.0	52.6	42.1	40.4	47.5	−8.2
全部换回第一次复现	55.9	51.1	41.2	40.8	47.3	−8.4

“只换”两组每组 1 个种子，其余 5 个种子。第一次复现的差距几乎全部来自预训练骨干；训练调度的影响不到 1 个点。

3.4 与原作者训练日志的对比



上图复现论文图 2：(a) 准确率，(b) 两项损失，(c) CORAL 距离；灰色虚线为原作者日志。两项损失的量级和走势与原作者几乎重合；不加 CORAL 时全量 CORAL 距离从 5×10^{-5} 增长到 4.6，结束时是 Deep CORAL 的约 500 倍，与论文的定性结论一致。

目标域准确率（%）：

	A→D	A→W	D→A	D→W	W→A	W→D
原作者，第 100 步	63.2	62.7	52.3	94.0	50.3	98.0
复现，第 100 步	61.3	59.3	51.4	93.9	48.1	98.4
原作者，最后一轮	66.8	66.4	52.8	95.7	51.5	99.2
复现，最后一轮	65.0	63.7	50.9	94.7	48.6	99.0

在 Amazon 作源域的任务上，差距从第 100 步就存在、之后不再扩大，更可能来自图片解码与缩放等像素级差异，而不是训练过程。

3.5 λ 的选择（A4）

论文用“训练结束时两项损失大致相等”选 λ。我们从 λ = 1 出发按这条规则标定（只用源域标签和损失值），与原作者的 λ 对比：

任务	原作者 λ	规则 λ*	增益（原作者 λ）	增益（规则 λ*）	增益（共用 A→W 的 λ*）
A→D	0.05	1.12	+2.4	−0.1	+0.2
A→W	0.8	1.10	+3.6	+3.4	—
D→A	0.001	0.63	−0.7	−6.4	−7.7
D→W	0.0001	0.62	−0.1	−2.5	−2.7
W→A	0.0007	0.65	+0.3	−1.0	−1.3
W→D	0.0001	0.66	+0.4	±0.0	+0.0

原作者的 λ 在训练结束时同样满足两项损失大致相等，但取值相差 8000 倍；规则从 λ = 1 出发，得到的 λ* 都在 0.6–1.1。这说明这条规则的解不唯一，取决于从哪里开始标定。在 DSLR、Webcam 作源域时，规则 λ* 比原作者大几百到几千倍，增益全部变差。

4. 诊断

以下分析只用已有训练日志，不需要新实验，详见 offline_analysis/results/offline_summary.md。

4.1 停在哪一步

用目标标签挑出的最优迭代只比最后一轮高 0.3–1.1 个点（CNN +0.9，Deep CORAL +0.8，CORAL + IM +0.4）。三种无标签选点规则（最小预测熵、最大 SND、最小全量 CORAL 距离）都不比最后一轮更好；“最小 CORAL 距离”对基线和 IM 会选到第 100 步左右，最差。论文报告最后一轮是合理的。

4.2 不用目标标签能否选出 λ 和方法

在 λ = 0、原作者 λ、规则 λ、共用 λ 四个候选中，对每个任务、每个种子按无标签指标挑一个（30 次）：

挑选规则	最常选中	平均准确率	遗憾值
最小预测熵	λ = 0（29 / 30 次）	69.4	1.2
最大 SND	λ = 0（21 / 30 次）	68.6	1.9
最小 CORAL 距离	最大的 λ（30 / 30 次）	68.0	2.6
固定用原作者 λ	—	70.3	0.2

遗憾值为每次候选中的最高准确率减去选中的准确率。每个指标都偏向“直接优化它”的选项：CORAL 会提高预测熵，所以熵最小总是选 λ = 0；CORAL 距离就是 CORAL 优化的量，所以总选最大的 λ。在方法之间挑选时也一样：熵和 SND 偏向 IM 类方法，结果（65.1–65.2）反而不如固定用 CORAL + IM（66.4）。这是 A4 不成立的直接证据，也是我们事先固定所有超参数的原因。

4.3 batch 上对齐了，不等于整个域对齐了（A3）

任务	训练 batch 损失 ÷ 全量距离（CNN）	同左（Deep CORAL）
A→D	2.7	7.1
A→W	2.2	7.0
D→A	1.5	3.3
D→W	2.4	3.2
W→A	1.6	3.1
W→D	2.5	3.5

以 A→W 为例，Deep CORAL 训练中看到的 batch CORAL 损失是 0.064，用全部图像算出的真实距离只有 0.009。放大来自两部分：有限样本估计协方差本身偏大（评估模式下 batch 距离是全量距离的 1.3–3.7 倍），训练模式的 Dropout 再放大 1.2–2.0 倍。真实距离越小，估计偏差占比越大，所以 CORAL 生效后，训练后期最小化的主要是估计噪声；论文图 2(b) 中“两项损失相等”，比较的其实是分类损失和一个以噪声为主的量。

4.4 λ 过大时特征并没有“退化”

论文把 λ 过大时的掉点归因于“退化特征”。若成立，λ 越大，有效秩应越低。目标域 fc8 的有效秩（最大 31）与准确率：

任务	CNN	原作者 λ	规则 λ*
D→A	23.0，51.6%	24.1，50.9%	28.4，45.2%
D→W	23.1，94.8%	23.5，94.7%	29.0，92.3%
W→A	22.6，48.3%	23.7，48.6%	28.6，47.4%
W→D	23.3，98.7%	23.7，99.0%	29.5，98.7%

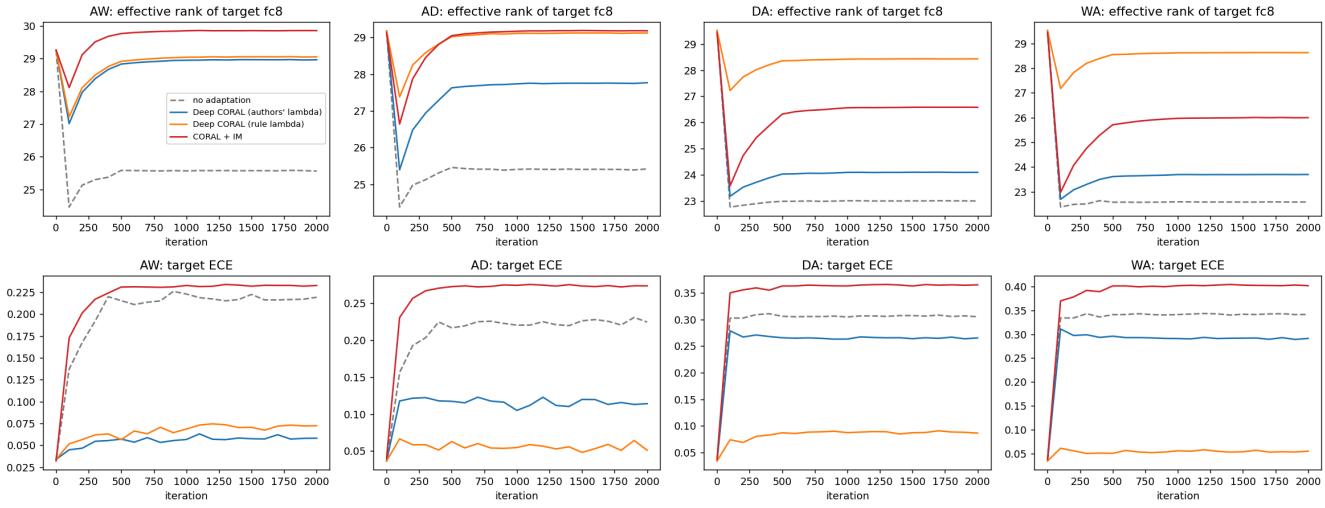
λ 增大几百到几千倍后，有效秩升高、准确率下降，fc7 的有效秩基本不变。我们的解释是：CORAL 让目标 logits 的协方差去匹配源域；源域在训练集上被完美分开，31 类各自散开，协方差谱接近均匀。λ 太大时，这种结构被硬套到不具备它的目标特征上，目标预测变得更分散、更不确定（预测熵从 0.95 升到 1.68），而不是塌缩。

4.5 校准性

A→W、A→D、D→A、W→A 四任务、种子 1–3 平均：

方法	准确率 %	ECE	NLL	平均预测熵
CNN	55.9	0.273	2.63	0.50
Deep CORAL（原作者 λ）	57.5	0.181	2.03	0.95
Deep CORAL（规则 λ）	54.9	0.066	1.75	1.68
IM	65.0	0.336	8.12	0.04
CORAL + IM	66.4	0.318	4.18	0.05

CORAL 明显改善校准，λ 越大越明显，但准确率可能下降。IM 正好相反：准确率大幅提高，NLL 却高达 8.1，说明错误的预测也非常自信。把 CORAL 加到 IM 上，准确率只多 1.4 个点，NLL 却减半。



5. 改进

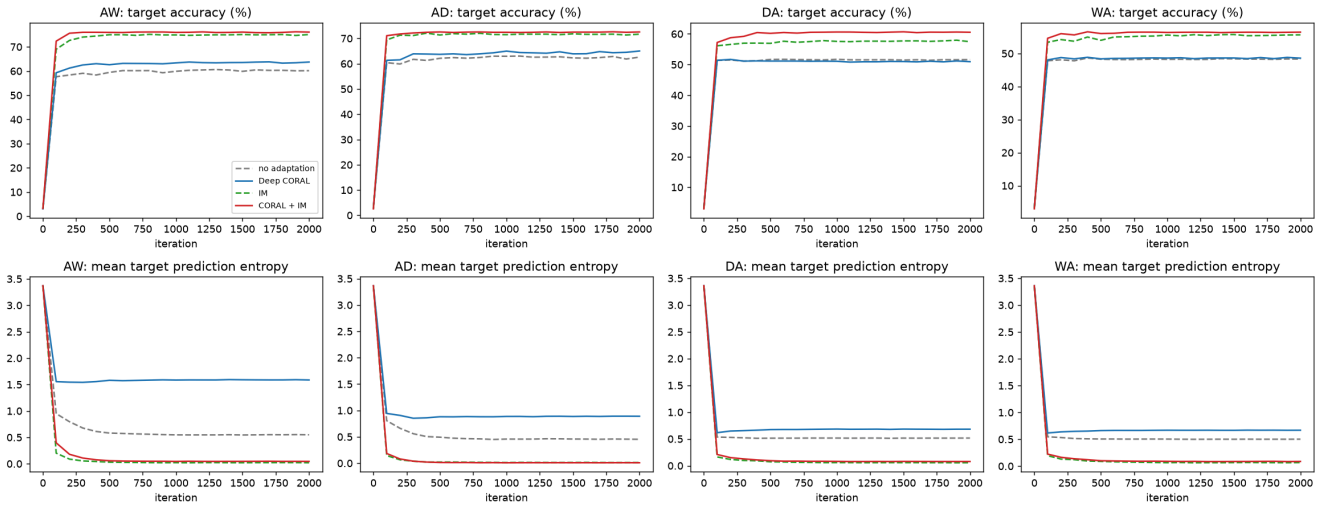
5.1 设计原则

- 每个改进只针对一处弱点，超参数事先固定，不用目标标签挑选。
- CORAL 的 λ 统一用原作者取值；对照组复用之前同种子的运行，配对比较。
- 只跑 A→W、A→D、D→A、W→A 四个任务、3 个种子；D→W、W→D 已接近 99%，没有提升空间。
- 新的损失项在启用之前，与同种子的对照运行逐位相同（已在假数据上核对）。

5.2 改进 1：目标域信息最大化

Deep CORAL 只对齐统计量，完全不利用目标域自身的结构。信息最大化在目标域上加两项损失，权重都取 β = 0.3：

- **单样本熵**：每个目标样本预测分布的熵，越小预测越确定，决策边界越远离样本密集区；
- **多样性**：batch 平均预测分布的负熵，越小各类别被预测得越均匀，防止所有样本塌到少数类。



目标域准确率（%，3 个种子）：

任务	CNN	Deep CORAL	IM	CORAL + IM	CORAL + IM − Deep CORAL
A→W	60.5	64.3	75.1	76.1	+11.8 [+7.1, +16.6]
A→D	62.6	65.7	71.7	72.6	+6.9 [+3.7, +10.1]
D→A	51.7	51.1	57.4	60.5	+9.4 [+8.0, +10.8]
W→A	48.6	48.8	55.7	56.5	+7.7 [+0.3, +15.1]
平均	55.9	57.5	65.0	66.4	+9.0 [+6.4, +11.5]

拆开看：只加 IM 就比 CNN 高 +9.1 [+7.5, +10.7]；在 IM 上再加 CORAL，只多 +1.4 [−0.8, +3.7]，四个任务中只有 D→A 显著（+3.1）。Deep CORAL 的瓶颈不在二阶统计量对齐得够不够，而在没有利用目标域结构。

多样性项必不可少（种子 1）：去掉它、只做熵最小化，预测塌到少数类上。

任务	只做熵最小化	CORAL + IM
A→W	4.2%（2 类）	75.7%（31 类）
A→D	16.5%（17 类）	72.1%（31 类）
D→A	3.5%（2 类）	59.8%（31 类）
W→A	3.9%（9 类）	59.4%（31 类）

括号内为目标预测覆盖的类别数。

结果对 β 不敏感（CORAL + IM，种子 1，%）：

任务	Deep CORAL	β = 0.1	β = 0.3	β = 1
A→W	63.3	78.0	75.7	70.2
A→D	64.3	70.7	72.1	70.5
D→A	51.0	60.6	59.8	59.1
W→A	48.3	57.6	59.4	55.5

β 在 0.1–1 之间都比 Deep CORAL 高 6–15 个点；这张表只说明敏感程度，不用来挑 β。

5.3 改进 2：类条件 CORAL（置信度伪标签）

针对 A2，在 CORAL + IM 之上按类别对齐 fc8 特征的均值和协方差（γ = 0.3，第 600 步启用）。源域用真实标签，目标域用当前 batch 预测中置信度 ≥ 0.9 的样本作伪标签。batch 128、31 类时每类平均只有约 4 个样本，所以每个域、每个类维护 32 个样本的特征队列，与当前 batch 合起来估计，梯度只回传到当前 batch。

任务	CORAL + IM	+ 类条件	变化
A→W	76.1	75.8	−0.3 [−1.1, +0.4]
A→D	72.6	73.1	+0.5 [−1.1, +2.1]
D→A	60.5	60.6	+0.1 [−1.7, +1.9]
W→A	56.5	57.0	+0.6 [−0.6, +1.7]
平均	66.4	66.6	+0.2 [−0.5, +0.9]

只对齐类均值、只对齐类协方差，以及 γ 取 0.1 或 1（种子 1）的结果都在 ±2 个点内波动，没有稳定趋势。对齐项本身在起作用：31 个类基本都被计入，类条件损失明显下降（D→A 从 3.17 降到 1.24）。问题在伪标签，见 5.5。

5.4 改进 3：类中心伪标签

既然置信度筛不掉错误伪标签，改用不看置信度的标签：每次评估时，用全部目标图像的 fc7 特征，按预测概率加权得到各类中心，把每个样本分给最近的类中心（余弦距离），再用硬标签重算一次中心。其余设置同改进 2。

任务	CORAL + IM	+ 类条件（类中心伪标签）	变化
A→W	76.1	75.6	−0.5
A→D	72.6	72.2	−0.3
D→A	60.5	60.9	+0.4
W→A	56.5	56.9	+0.4
平均	66.4	66.4	±0.0 [−1.1, +1.1]

消融（种子 1）中，只保留类中心与预测一致的样本，四任务为 75.8 / 72.7 / 61.9 / 59.9；在类中心伪标签上再加自训练（目标样本对伪标签的交叉熵，权重 0.3），为 74.6 / 72.5 / 64.2 / 62.8，在 D→A、W→A 上比 CORAL + IM 高 4.4、3.4 个点，是唯一的正面信号，但只有 1 个种子，A→W 还略有下降，尚未验证。

5.5 为什么两种伪标签都没用

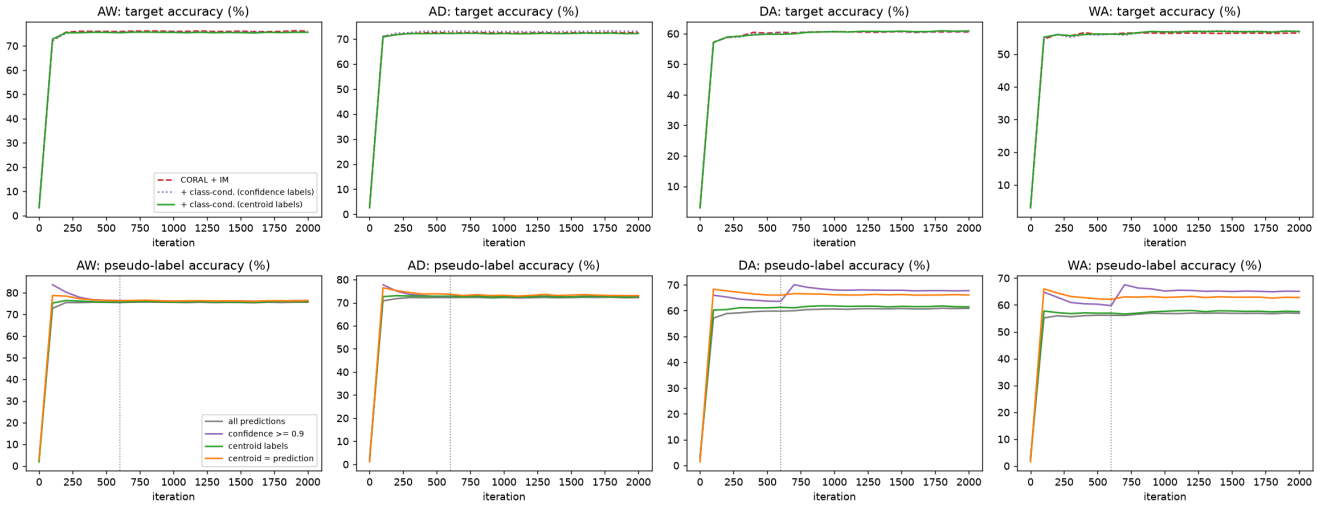
最后一轮的伪标签质量（%，用目标标签计算，仅用于分析）：

任务	通过 0.9 阈值的比例	其中正确	类中心标签准确率	模型预测准确率	类中心与预测一致
A→W	98.7	76.4	75.9	75.6	98.1
A→D	99.3	73.2	72.6	72.2	98.5
D→A	84.2	67.3	61.5	60.9	88.6
W→A	80.5	64.4	57.5	56.9	86.0

前两列来自改进 2 的模型，后三列来自改进 3 的模型，均为 3 个种子平均。

- IM 让模型过度自信，0.9 的阈值几乎筛不掉错误：A→W 上 98.7% 的目标样本通过了阈值，其中约四分之一是错的。
- 类中心标签与模型预测在 Amazon 作源域的任务上有 98% 以上是同一个标签，准确率也几乎相同。IM 训练之后，特征的聚类结构和预测已经互相吻合。
- 伪标签准确率在训练中持平或略升（D→A +3.1、W→A +4.4），没有出现确认偏差。

所以不论用置信度筛选还是在特征空间聚类，伪标签都来自同一个模型，给不出模型不知道的信息。要让类条件对齐生效，需要模型之外的信息来源，例如不同数据增强下预测的一致性，或多个模型的集成。



6. 结论

1. 对齐原作者的 Caffe 配置后，复现对上了论文：基线只差 0.8 个点，Deep CORAL 的增益显著为正，但只有论文的一半。第一次复现的差距几乎全部来自预训练骨干。
2. Deep CORAL 的增益依赖 λ，而 λ 在无监督条件下定不下来：论文的规则解不唯一，无标签指标都偏向“直接优化它”的选项（A4）。
3. batch 内的 CORAL 损失以估计噪声为主（A3）；λ 过大时的危害不是特征塌缩，而是把源域的协方差结构硬套到目标特征上。
4. 目标域信息最大化是最有效的改进，平均 +9.0；CORAL 在其上主要起抑制过度自信的作用（NLL 减半），准确率只多 1.4。
5. 补类别信息（A2）需要可靠的伪标签，而 IM 之后从模型自身得到的伪标签已带不来新信息，类条件 CORAL 没有额外提升。

7. 局限与下一步

- 改进实验每个配置 3 个种子，消融和敏感性实验只有 1 个种子；W→A 的种子间标准差达 2.5–2.9，单种子差异小于 3 个点时不宜下结论。
- 原作者的 λ 可能参考过目标域结果；我们的改进沿用了这些 λ，但新增的超参数都事先固定。
- 只在 AlexNet 级骨干上实验，没有测试 ResNet 等带 BN 的骨干，也没有做方案中的损失替换（MMD、DANN 等）、对齐层位置和受控合成偏移实验。
- Fisher 比和温度缩放需要逐样本特征和源域验证集，batch 大小对估计误差的影响需要模型权重，都没有做。
- 下一步：用 3 个种子验证自训练；补上述需要特征的分析。

结果文件

内容	位置
阶段一：复现、λ 标定、差距归因	stage1_reproduction/results/stage1_summary.md
阶段二：信息最大化	stage2_improvement/results/improve_summary.md
阶段三：类条件 CORAL	stage3_class_conditional/results/cc_summary.md
阶段四：类中心伪标签	stage4_pseudo_labels/results/pl_summary.md
离线分析	offline_analysis/results/offline_findings.md
原作者训练日志的参考曲线	stage1_reproduction/official_reference.json

运行方法见 README.md。